

Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

## Análisis: Mobile price classification con SVM y Redes neuronales

### 1. Introducción

El problema original tiene una breve descripción contextual (.sic):

Bob has started his own mobile company. He wants to give tough fight to big companies like Apple,Samsung etc.

He does not know how to estimate price of mobiles his company creates. In this competitive mobile phone market you cannot simply assume things. To solve this problem he collects sales data of mobile phones of various companies.

Bob wants to find out some relation between features of a mobile phone(eg:- RAM,Internal Memory etc) and its selling price. But he is not so good at Machine Learning. So he needs your help to solve this problem.

In this problem you do not have to predict actual price but a price range indicating how high the price is. (Sharma, 2018)

La variable objetivo es la variable “price\_range”. En este análisis no se usarán los dos datasets, solo `train.csv` que corresponde a los datos de entrenamiento.

#### 1.1. Bibliotecas a utilizar

En el presente análisis se comparará el funcionamiento de una SVM y una red neuronal básica por lo tanto se requieren las siguientes bibliotecas.

```
[1]: from sklearn import metrics
from sklearn import svm
from sklearn.model_selection import train_test_split, RandomizedSearchCV
from tensorflow.keras.layers import Dense
from tensorflow.keras.models import Sequential
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
plt.rcParams['figure.dpi'] = 300
plt.rcParams['savefig.dpi'] = 300
```

### 2. Carga de dataset y análisis descriptivo de datos

```
[2]: df_train = pd.read_csv("ds/train.csv")
```

Según los datos proporcionados no existen valores perdidos. Además todas las columnas tienen valores numéricos.

```
[3]: df_train.info()
```

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2000 entries, 0 to 1999
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   battery_power         2000 non-null   int64
1   blue                  2000 non-null   int64
2   clock_speed           2000 non-null   float64
3   dual_sim              2000 non-null   int64
4   fc                    2000 non-null   int64
5   four_g                2000 non-null   int64
6   int_memory            2000 non-null   int64
7   m_dep                 2000 non-null   float64
8   mobile_wt             2000 non-null   int64
9   n_cores               2000 non-null   int64
10  pc                    2000 non-null   int64
11  px_height             2000 non-null   int64
12  px_width              2000 non-null   int64
13  ram                   2000 non-null   int64
14  sc_h                  2000 non-null   int64
15  sc_w                  2000 non-null   int64
16  talk_time             2000 non-null   int64
17  three_g               2000 non-null   int64
18  touch_screen          2000 non-null   int64
19  wifi                  2000 non-null   int64
20  price_range           2000 non-null   int64
dtypes: float64(2), int64(19)
memory usage: 328.2 KB
```

Los metadatos del dataframe corresponden al siguiente diccionario. De esta forma, es posible saber que significa un dato en particular. Esto puede no ser indispensable para el código pero si resulta de gran importancia en la interpretación y análisis de resultados.

```
[4]: metadata = {
    'battery_power': 'Capacidad de la batería mAh',
    'blue': 'Tiene bluetooth',
    'clock_speed': 'Velocidad de reloj del microprocesador',
    'dual_sim': 'Tiene soporte dual sim',
    'fc': 'Resolución de cámara frontal en megapíxeles',
    'four_g': 'Tiene 4G',
    'int_memory': 'Memoria interna en Gigabytes',
    'm_dep': 'Profundidad móvil en cm',
    'mobile_wt': 'Peso del teléfono móvil',
    'n_cores': 'Número de núcleos del procesador',
    'pc': 'Megapíxeles de la cámara principal',
    'px_height': 'Altura de resolución de píxeles',
    'px_width': 'Ancho de resolución de píxeles',
    'ram': 'Memoria RAM en megabytes',
```

Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

```
'sc_h': 'Altura de la pantalla del móvil en cm',
'sc_w': 'Ancho de pantalla del móvil en cm',
'talk_time': 'Máximo tiempo que durará una sola carga de batería_
↳ cuando se habla por teléfono',
'tres_g': 'Tiene 3G',
'touch_screen': 'Tiene pantalla táctil',
'wifi': 'Tiene wifi',
'price_range': 'Rango de precios de 0 (costo bajo), 1 (costo_
↳ medio), 2 (costo alto), 3 (costo muy alto)',
}
metadata['n_cores']
```

[4]: 'Número de núcleos del procesador'

[5]: df\_train.describe().transpose()

```
[5]:
```

	count	mean	std	min	25%	50%_
battery_power	2000.0	1238.51850	439.418206	501.0	851.75	1226.0
blue	2000.0	0.49500	0.500100	0.0	0.00	0.0
clock_speed	2000.0	1.52225	0.816004	0.5	0.70	1.5
dual_sim	2000.0	0.50950	0.500035	0.0	0.00	1.0
fc	2000.0	4.30950	4.341444	0.0	1.00	3.0
four_g	2000.0	0.52150	0.499662	0.0	0.00	1.0
int_memory	2000.0	32.04650	18.145715	2.0	16.00	32.0
m_dep	2000.0	0.50175	0.288416	0.1	0.20	0.5
mobile_wt	2000.0	140.24900	35.399655	80.0	109.00	141.0
n_cores	2000.0	4.52050	2.287837	1.0	3.00	4.0
pc	2000.0	9.91650	6.064315	0.0	5.00	10.0
px_height	2000.0	645.10800	443.780811	0.0	282.75	564.0
px_width	2000.0	1251.51550	432.199447	500.0	874.75	1247.0
ram	2000.0	2124.21300	1084.732044	256.0	1207.50	2146.5
sc_h	2000.0	12.30650	4.213245	5.0	9.00	12.0
sc_w	2000.0	5.76700	4.356398	0.0	2.00	5.0
talk_time	2000.0	11.01100	5.463955	2.0	6.00	11.0
three_g	2000.0	0.76150	0.426273	0.0	1.00	1.0
touch_screen	2000.0	0.50300	0.500116	0.0	0.00	1.0
wifi	2000.0	0.50700	0.500076	0.0	0.00	1.0
price_range	2000.0	1.50000	1.118314	0.0	0.75	1.5

	75%	max
battery_power	1615.25	1998.0
blue	1.00	1.0
clock_speed	2.20	3.0
dual_sim	1.00	1.0
fc	7.00	19.0
four_g	1.00	1.0
int_memory	48.00	64.0

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

```

m_dep          0.80    1.0
mobile_wt      170.00  200.0
n_cores        7.00    8.0
pc             15.00  20.0
px_height      947.25 1960.0
px_width       1633.00 1998.0
ram            3064.50 3998.0
sc_h           16.00   19.0
sc_w           9.00   18.0
talk_time      16.00  20.0
three_g        1.00   1.0
touch_screen   1.00   1.0
wifi           1.00   1.0
price_range     2.25   3.0


```

Aún así parece que no todas las variables son realmente numéricas, pues no caen en valores continuos. Como ejemplo es posible observar la columna objetivo, la cual por medio de números distingue cuatro categorías, mismas que se detallan en los metadatos.

```
[6]: sns.countplot(x='price_range', data=df_train)
plt.title(metadata['price_range'], fontsize=12)
```

```
[6]: Text(0.5, 1.0, 'Rango de precios de 0 (costo bajo), 1 (costo medio), 2 (costo
    ↪alto), 3 (costo muy alto)')
```

Rango de precios de 0 (costo bajo), 1 (costo medio), 2 (costo alto), 3 (costo muy alto)



## 2.1. Variables categóricas

Es importante observar entonces que datos son categóricos y examinarlos como tal.

Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

```
[7]: for i in df_train.columns:
      print(f'Valores posibles de {i.title()}: {df_train[i].unique()}')
```

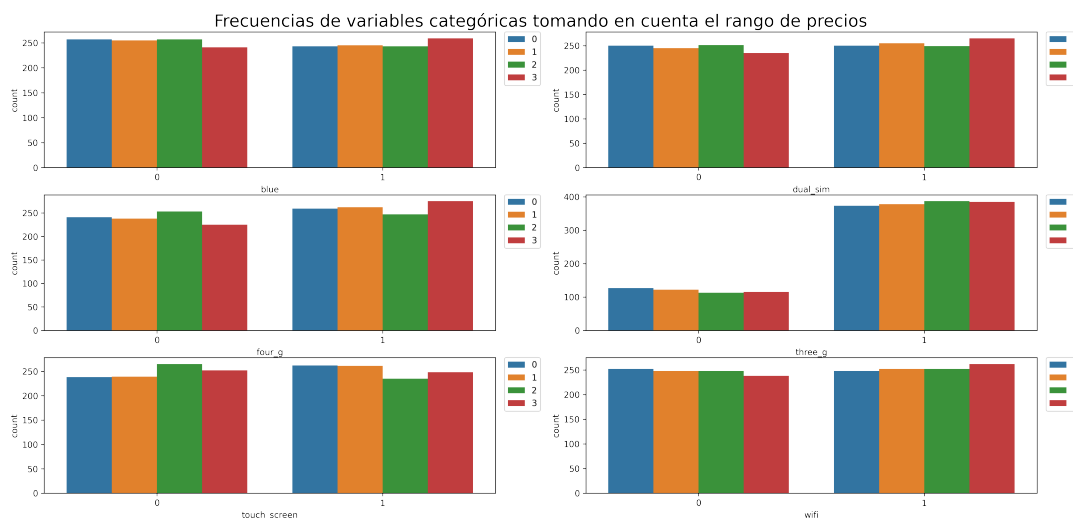
```
Valores posibles de Battery_Power: [ 842 1021  563 ... 1139 1467  858]
Valores posibles de Blue: [0 1]
Valores posibles de Clock_Speed: [2.2 0.5 2.5 1.2 1.7 0.6 2.9 2.8 2.1 1.
↪ 0.9
1.1 2.6 1.4 1.6 2.7 1.3 2.3
2.  1.8 3.  1.5 1.9 2.4 0.8 0.7]
Valores posibles de Dual_Sim: [0 1]
Valores posibles de Fc: [ 1  0  2 13  3  4  5  7 11 12 16  6 15  8  9 10
↪ 18 17
14 19]
Valores posibles de Four_G: [0 1]
Valores posibles de Int_Memory: [ 7 53 41 10 44 22 24  9 33 17 52 46 13
↪ 23 49 19
39 47 38  8 57 51 21  5
60 61  6 11 50 34 20 27 42 40 64 14 63 43 16 48 12 55 36 30 45 29 58 25
3 54 15 37 31 32  4 18  2 56 26 35 59 28 62]
Valores posibles de M_Dep: [0.6 0.7 0.9 0.8 0.1 0.5 1.  0.3 0.4 0.2]
Valores posibles de Mobile_Wt: [188 136 145 131 141 164 139 187 174  93
↪ 182 177
159 198 185 196 121 101
81 156 199 114 111 132 143  96 200  88 150 107 100 157 160 119  87 152
166 110 118 162 127 109 102 104 148 180 128 134 144 168 155 165  80 138
142  90 197 172 116  85 163 178 171 103  83 140 194 146 192 106 135 153
89  82 130 189 181  99 184 195 108 133 179 147 137 190 176  84  97 124
183 113  92  95 151 117  94 173 105 115  91 112 123 129 154 191 175  86
98 125 126 158 170 161 193 169 120 149 186 122 167]
Valores posibles de N_Cores: [2 3 5 6 1 8 4 7]
Valores posibles de Pc: [ 2  6  9 14  7 10  0 15  1 18 17 11 16  4 20 13
↪ 3 19
8  5 12]
Valores posibles de Px_Height: [ 20  905 1263 ...  528  915  483]
Valores posibles de Px_Width: [ 756 1988 1716 ...  743 1890 1632]
Valores posibles de Ram: [2549 2631 2603 ... 2032 3057 3919]
Valores posibles de Sc_H: [ 9 17 11 16  8 13 19  5 14 18  7 10 12  6 15]
Valores posibles de Sc_W: [ 7  3  2  8  1 10  9  0 15 13  5 11  4 12  6
↪ 17 14 16
18]
Valores posibles de Talk_Time: [19  7  9 11 15 10 18  5 20 12 13  2  4
↪ 3 16  6
14 17  8]
Valores posibles de Three_G: [0 1]
Valores posibles de Touch_Screen: [0 1]
Valores posibles de Wifi: [1 0]
Valores posibles de Price_Range: [1 2 3 0]
```

Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

Las variables categóricas parecen ser: blue, dual\_sim, four\_g, three\_g, touch\_screen, wifi y price\_range. Debido a que price\_range es nuestra variable objetivo, en seguida se grafican las frecuencias de las otras variables categóricas tomando en cuenta el rango de precios.

```
[8]: cv=['blue', 'dual_sim', 'four_g', 'three_g', 'touch_screen', 'wifi']
fig=plt.figure(figsize=(21,10))
plt.title('Frecuencias de variables categóricas tomando en cuenta el
↵rango de precios',fontdict={'fontsize':20})
plt.axis('off')

for i in range(len(cv)):
    fig.add_subplot(3,2,i+1)
    sns.countplot(data=df_train,x=cv[i], hue='price_range')
    plt.legend(bbox_to_anchor=(1.02, 1), borderaxespad=0)
```



Es posible observar que los teléfonos más costosos cuentan con más de estas características, salvo en el caso de touch\_screen, donde no hay diferencia frecuencial visible. La variable three\_g parece ser más significativa ya que la división es un poco más clara. También hay que matizar que esta diferencia no es suficiente para distinguir invariablemente las categorías de rango de precio.

## 2.2. Variables numéricas



Se repetirá el procedimiento anterior procedimiento para las variables que son efectivamente numéricas pues servirá para observar el contraste entre los tipos de variables.

```
[9]: nv=['battery_power', 'clock_speed', 'fc', 'int_memory', 'm_dep',
↵'mobile_wt', 'n_cores', 'pc', 'px_height', 'px_width', 'ram',
↵'sc_h', 'sc_w', 'talk_time']
fig=plt.figure(figsize=(8,64))
```


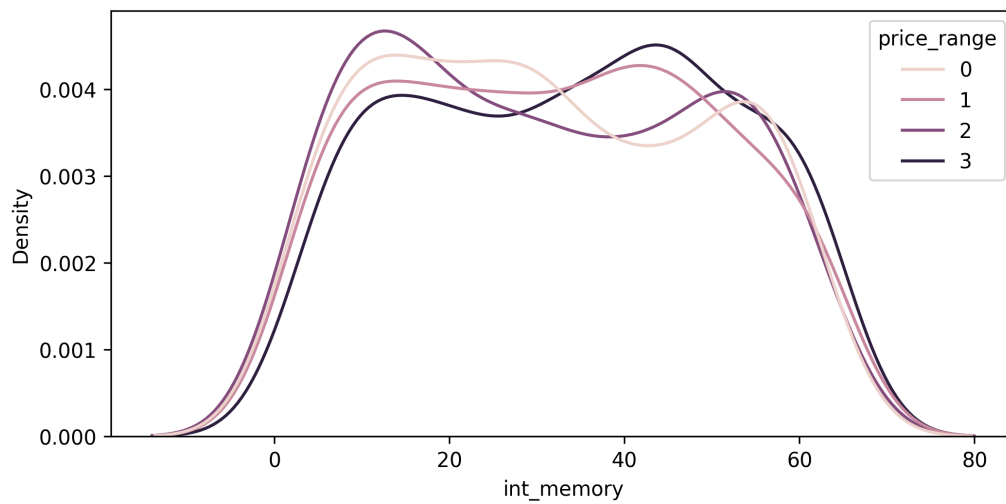

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

```
plt.title('Frecuencia de variables numéricas tomando en cuenta el rango_
de precios')
plt.axis('off')

for i in range(len(nv)):
    fig.add_subplot(14,1,i+1)
    sns.kdeplot(data=df_train, x=nv[i], hue='price_range')
```



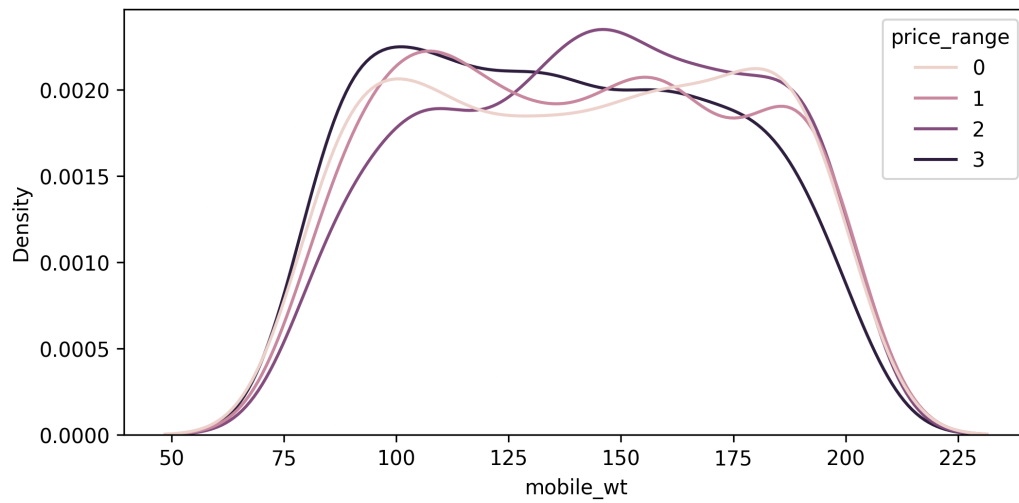


Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022








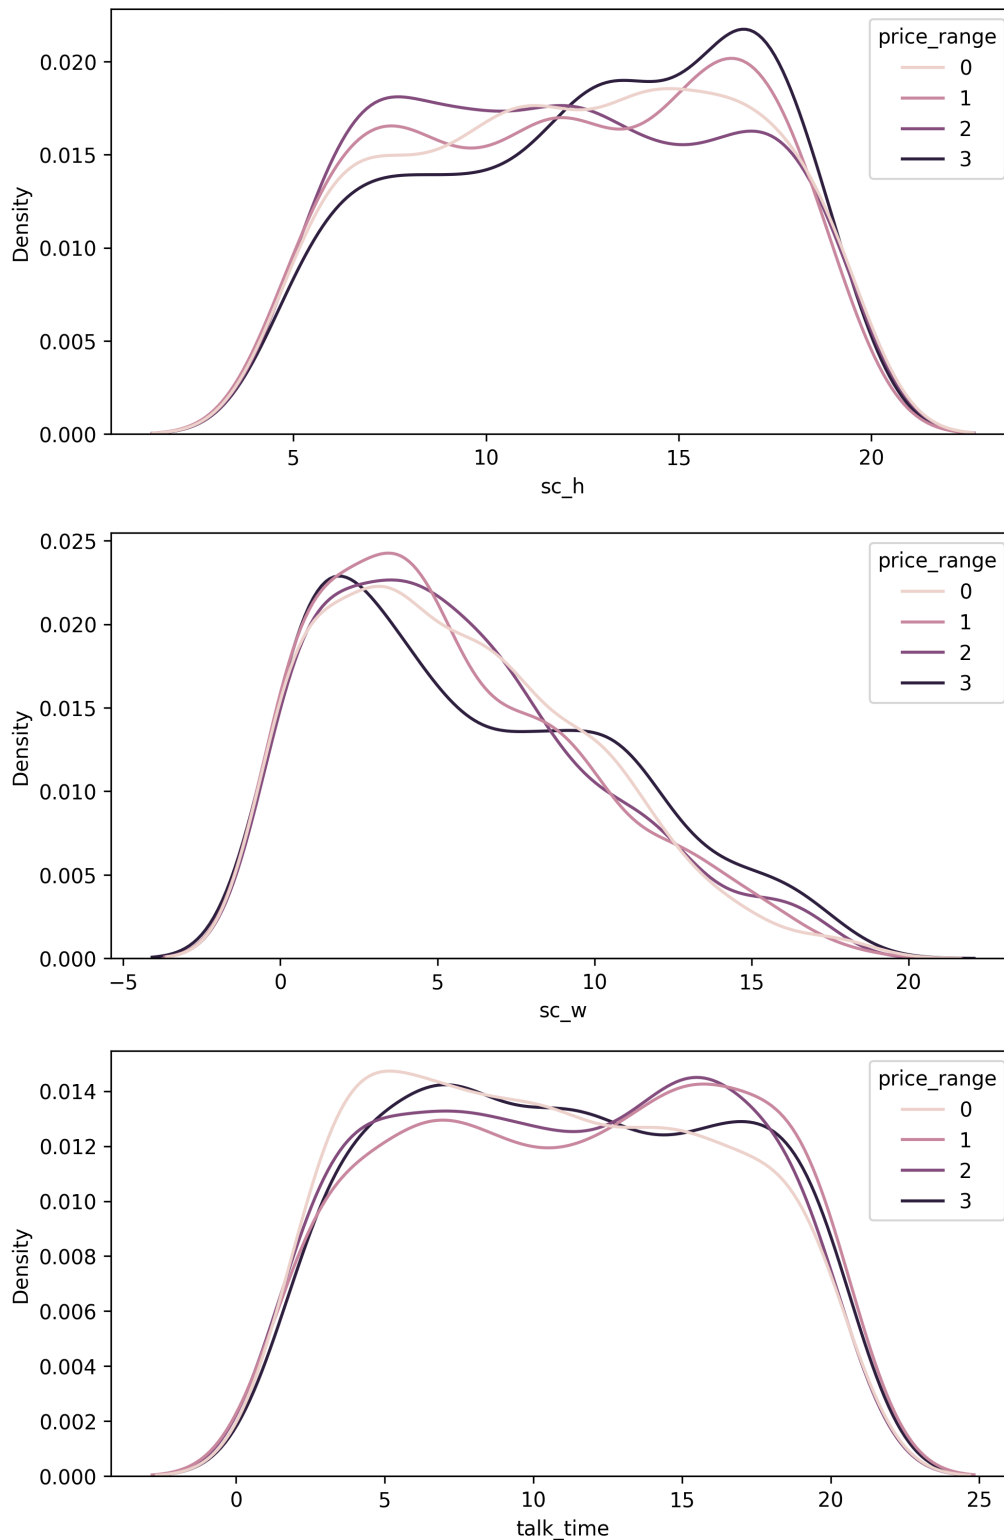
Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022



Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022



Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022



La dentro de las gráficas anteriores lo más destacado es aquella que representa la variable `ram`. En dicha representación se distinguen muy claramente los segmentos de precio, es posible pensar que que la variable `ram`, tenga una correlación alta respecto a `price_range`, mientras otras como `clock_speed` sean de muy poca relevancia. No hay que perder de vista que la

Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022


correlación es distinto a la causa: la correlación indica que el valor de ambas variables depende de la misma causa.

### 3. Matriz de correlación

La matriz es indispensable para distinguir la importancia de las variables y así pensar en un mejor modelo.

```
[10]: plt.figure(figsize=(16,9))
      corrmat = df_train.corr()
      sns.heatmap(corrmat, cmap='coolwarm', vmax=.8, fmt='.1f', annot=True)
```

[10]: <AxesSubplot:>



```
[11]: df_train.corr()['price_range'].sort_values(ascending=False)[1:21]
```

```
[11]: ram          0.917046
      battery_power 0.200723
      px_width      0.165818
      px_height     0.148858
      int_memory     0.044435
      sc_w           0.038711
      pc             0.033599
      three_g        0.023611
      sc_h           0.022986
      fc             0.021998
```

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

```

talk_time      0.021859
blue           0.020573
wifi           0.018785
dual_sim       0.017444
four_g         0.014772
n_cores        0.004399
m_dep          0.000853
clock_speed    -0.006606
mobile_wt      -0.030302
touch_screen   -0.030411
Name: price_range, dtype: float64

```

Tal y como se dijo anteriormente, la variable `ram` tiene una alta correlación con la variable objetivo.

#### 4. SVM

Se implementará una SVM. Al trabajar con métodos supervisados es necesario dividir el `dataframe` en dos partes.

```

[12]: train, test = train_test_split(df_train, test_size=0.2)
predictors = cv + nv
#predictors = ['ram', 'battery_power', 'px_width', 'px_height',
↳ 'int_memory']
target = ['price_range']

```

Ahora, ante la diversidad de hiperparámetros se crea la SVM al mismo tiempo que se busca el mejor modelo posible. Este proceso es muy lento, a continuación se muestran solo los hiperparámetros más relevantes, otros fueron descartados pues en una ejecución individual dieron resultados deficientes.

```

[13]: parameters = [{'kernel': ['rbf', 'linear'], 'gamma': ['scale', 'auto'],
↳ 'C': [0.5, 1.0, 1.5, 2.0, 2.5]}]
svmc = RandomizedSearchCV(svm.SVC(decision_function_shape='ovr'),
↳ param_distributions=parameters, cv=5, scoring='accuracy')
svmc.fit(train[predictors], np.ravel(train[target]))
svmc.best_params_

```

```

[13]: {'kernel': 'linear', 'gamma': 'scale', 'C': 1.0}

```


```

[14]: svm_predicted = svmc.predict(test[predictors])
crosstab = sns.heatmap(pd.crosstab(test[target].values.ravel(),
↳ svm_predicted),
                        cmap='gist_yarg', vmax=.8, fmt='g', annot=True)
crosstab.set_xlabel('Predicciones')
crosstab.set_ylabel('Reales')
print("Accuracy: ", metrics.accuracy_score(svm_predicted, np.
↳ ravel(test[target])))

```

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

Accuracy: 0.98



Los resultados de la SVM resultan bastante prometedores, la precisión alcanzada es muy alta, en alguna ejecución llegó a ser del 99 %, sin embargo, se consigue en pocos casos.

## 5. Red Neuronal

La red neuronal ha resultado ser más complicada de implementar debido a que requiere el diseño de la las capas de la red. Aquí se presenta una estructura básica donde hay tres capas con 16, 12 y 4 neuronas; las primeras dos tienen función de activación `relu` y la última `softmax`. (rickytb, 2021; Team, 2022)

```
[15]: nn = Sequential()
nn.add(Dense(units=16, input_dim=20, activation='relu'))
nn.add(Dense(units=12, activation='relu'))
nn.add(Dense(units=4, activation='softmax'))
```

WARNING:tensorflow:From /srv/conda/envs/notebook/lib/python3.7/site-packages/tensorflow\_core/python/ops/resource\_variable\_ops.py:1630:

↳ calling

BaseResourceVariable.\_\_init\_\_ (from tensorflow.python.ops.

↳ resource\_variable\_ops)

with constraint is deprecated and will be removed in a future version.

Instructions for updating:

If using Keras pass `*_constraint` arguments to layers.

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022


```
[16]: nn.compile(loss='sparse_categorical_crossentropy', optimizer='adam',
↳ metrics=['accuracy'])
```

```
[17]: historial = nn.fit(train[predictors], np.ravel(train[target]),
↳ epochs=600, batch_size=4, verbose=0)
```

```
2022-04-24 19:02:24.795969: W tensorflow/stream_executor/platform/
↳ default/dso_loader.cc:55] Could not load dynamic library 'libcuda.so.
↳ 1'; dLError: libcuda.so.1: cannot open shared object file: No such
↳ file or directory
2022-04-24 19:02:24.796021: E tensorflow/stream_executor/cuda/
↳ cuda_driver.cc:318] failed call to cuInit: UNKNOWN ERROR (303)
2022-04-24 19:02:24.796055: I tensorflow/stream_executor/cuda/
↳ cuda_diagnostics.cc:156] kernel driver does not appear to be running
↳ on this host (jupyter-genomorro-2dunir-2djkvlkign): /proc/driver/
↳ nvidia/version does not exist
2022-04-24 19:02:24.796895: I tensorflow/core/platform/cpu_feature_guard.
↳ cc:142] Your CPU supports instructions that this TensorFlow binary
↳ was not compiled to use: AVX2 FMA
2022-04-24 19:02:24.803463: I tensorflow/core/platform/profile_utils/
↳ cpu_utils.cc:94] CPU Frequency: 2299995000 Hz
2022-04-24 19:02:24.804009: I tensorflow/compiler/xla/service/service.cc:
↳ 168] XLA service 0x55ab9e131980 initialized for platform Host (this
↳ does not guarantee that XLA will be used). Devices:
2022-04-24 19:02:24.804053: I tensorflow/compiler/xla/service/service.cc:
↳ 176] StreamExecutor device (0): Host, Default Version
```

En la siguiente gráfica se observa que incluso con 600 epoch el modelo continúa disminuyendo la pérdida, aunque la rapidez disminuye al acercarse a los 500 epoch, por lo que se considera un buen valor para el entrenamiento.

```
[18]: plt.xlabel("# Epoch")
plt.ylabel("Magnitud de pérdida")
plt.plot(historial.history["loss"])
```



Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022


```
[19]: nn_pred = nn.predict(test[predictors])
```

El resultado de la red neuronal no es legible inmediatamente, se requiere convertir las predicciones a sus respectivas etiquetas ([rickytb, 2021](#)). Para ello se crea una función que realice esta conversión.

```
[20]: # Convertir las predicciones a sus respectivas etiquetas
def pred_to_label(predictions):
    pred = list()
    for i in range(len(predictions)):
        pred.append(np.argmax(predictions[i]))
    return pred
```

```
[21]: nn_predicted = pred_to_label(nn_pred)
crosstab = sns.heatmap(pd.crosstab(test[target].values.ravel(), np.
    ↪ array(nn_predicted)),
                        cmap='gist_yarg', vmax=.8, fmt='g', annot=True)
crosstab.set_xlabel('Predicciones')
crosstab.set_ylabel('Reales')
print("Accuracy: ", metrics.accuracy_score(nn_predicted, np.
    ↪ ravel(test[target])))
```

Accuracy: 0.9625



La red neuronal no ha alcanzado la gran precisión que logró la SVM pero el resultado no se ha



Asignatura	Datos del alumno	Fecha
Aprendizaje automático	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

alejado realmente. Si se considera que este modelo fue creado a partir de la documentación básica de la biblioteca que lo implementa y no ha sido totalmente personalizado, es posible pensar que el resultado es positivo y podría alcanzar mejores predicciones con mayor tiempo.

## 6. Comparación entre métodos

Como ya se ha visto, la precisión conseguida por la SVM es superior a la obtenida en la red neuronal. Habrá que considerar que la potencia de cómputo ha limitado la red neuronal, por lo tanto, para comparar mejor los algoritmos se usarán las métricas proporcionadas por `sklearn`.

```
[22]: print(metrics.classification_report(test[target].values.ravel(),  
    ↪svm_predicted))
```

	precision	recall	f1-score	support
0	1.00	0.98	0.99	101
1	0.98	0.98	0.98	101
2	0.97	0.97	0.97	96
3	0.97	0.99	0.98	102
accuracy			0.98	400
macro avg	0.98	0.98	0.98	400
weighted avg	0.98	0.98	0.98	400

```
[23]: print(metrics.classification_report(test[target].values.ravel(),  
    ↪nn_predicted))
```

	precision	recall	f1-score	support
0	0.93	0.99	0.96	101
1	0.97	0.92	0.94	101
2	0.97	0.97	0.97	96
3	0.99	0.97	0.98	102
accuracy			0.96	400
macro avg	0.96	0.96	0.96	400
weighted avg	0.96	0.96	0.96	400

Los resultados son realmente igualados. Los mejores números presentados por la SVM no hacen gran diferencia. El *recall*, la capacidad del clasificador para encontrar todas las muestras positivas pueden tener números iguales según sea la ejecución del *notebook* de Python. El *f1-score* que se interpreta como una media armónica de precisión y recall, llega en alguna categoría, de cualquiera de los modelos, a su mejor valor (1), según sea la ejecución del *notebook*.

Parece que con la implementación aquí elaborada de ambos modelos, dependerá más de ejecutar el *notebook* hasta encontrar una ejecución que logre los mejores resultados que el usuario pueda esperar. Ahora bien, es importante señalar que la red neuronal parece menos consistente entre categorías que la SVM, en otras palabras, la SVM clasifica cada una de las categorías

Asignatura	Datos del alumno	Fecha
<b>Aprendizaje automático</b>	Apellidos: Domínguez Espinoza Nombre: Edgar Uriel	6 de mayo de 2022

con presiciones similares, mientras que en la red neuronal se observa que tiene notablemente menor precisión en alguna de las categorías.

## 7. Conclusión

En el presente análisis se utilizó un dataset llamado *Mobile price classification*. Se realizó un estudio estadístico general del dataset y se encontraron dos mil muestras en el mismo.

Se decidió aplicar dos algoritmos avanzados: SVM y redes neuronales. Estos algoritmos requieren trabajo al afinar los hiperparámetros de cada modelo, si bien son herramientas muy poderosas, también hay que decir que ajustarlas para solucionar el problema puede ser más costoso que usar otro algoritmo más básico.

En ejemplos sencillos como el resuelto en este documento, dichos hiperparámetros son ajustables con cierta sencillez. Aún así, la fase de entrenamiento es más lenta si se considera que el dataset es de solo 2000 muestras. Si a lo anterior se sumaran muestras con overlapping, la SVM particularmente tenderá a cometer un mayor número de errores. La red neuronal incluso sugería el uso de una tarjeta gráfica y otras características para el CPU. Este mensaje puede observarse en la correspondiente ejecución de la red neuronal del presente análisis.

Si el dataset tiene muchas dimensiones, la SVM puede ser una excelente alternativa. Aunque no podrán ser visualizadas gráficamente, este algoritmo lidiará bien con el dataset incluso si el número de dimensiones supera el número de muestras, como en el procesamiento de imágenes. Por su parte, las redes neuronales pueden ser más útiles con información más desestructurada o en datos más complejos sin querer abusar del método prueba/error.

## Referencias

rickytb (2021). ejemplo-redes-neuronales. *Kaggle*.

Sharma, A. (2018). Mobile price classification: classify mobile price range. *Mobile Price Classification classify mobile price range*.

Team, K. (2022). Keras documentation: Model training apis.